Mineração de Métricas DORA em Repositórios Open-Source com GitHub Actions

Arlindo Junior[1], **Arthur Astolfi Cardoso**[1], **Camila Melo Ferreira**[1]

[1]Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais
Belo Horizonte – MG – Brasil

Curso	Engenharia de Software	**Professor(a)**	Danilo Maia
Disciplina	Lab. de Experimentação de Software	**Turno / Período**	Noite / 6º
Laboratório	Lab03 – Mineração de Métricas DORA	**Data de entrega**	22/10/2026
Grupo (trio)	Arlindo Junior · Arthur Astolfi Cardoso · Camila Melo Ferreira		
Repositório	`https://github.com/ArlindoSPJr/LAB03-ExperimentacaoSoftware`		
GitHub Projects	`https://github.com/users/ArlindoSPJr/projects/5`		

Resumo. *Medimos as quatro métricas DORA em 300 repositórios open-source populares que usam GitHub Actions, numa janela de 12 meses (out/2025 a set/2026), com dados minerados da API REST do GitHub por um pipeline próprio. O repositório típico publica 0,39 release por semana, tem lead time de 11 a 12 dias, CFR de 4,8% pelo CI e de 20% pelas releases corretivas, e se recupera de uma falha de CI em 2,3 horas. Frequência e CFR por entrega estão correlacionados ($\rho = 0{,}58$), a idade do projeto é o fator mais associado ao desempenho, e a classificação DORA muda para um quarto a um terço dos repositórios quando a definição operacional muda.*

1. Introdução

As métricas DORA são o padrão de mercado para medir o desempenho de entrega: duas medem velocidade (frequência de deploy e lead time) e duas medem estabilidade (taxa de falha e tempo de recuperação) [Forsgren et al. 2018]. Elas vêm de questionários respondidos por equipes. Projetos open-source publicam releases e executam CI em público, o que permite aproximá-las com dados abertos e verificar se afirmações do DORA, como a de que velocidade e estabilidade não são um *trade-off*, se repetem nesse contexto. A Tabela 1 traz as questões de pesquisa e as hipóteses informais do grupo.

Contribuições do grupo (30%): a RQ08 com a *rework rate*; a heurística de release corretiva refinada em três versões; e a amostragem sistemática de comparações nas variantes de deploy (Seção 3.6).

2. Contexto

Este é o terceiro laboratório da disciplina, feito em três sprints e uma entrega final de replicação cruzada; o artigo é a base do artigo do Lab04. O objeto de estudo são repositórios open-source com pelo menos 1.000 estrelas que usam GitHub Actions: a release publicada faz o papel de deploy, e as execuções de CI no *default branch*, o de sinais de falha e de recuperação. As métricas e as faixas Elite, High, Medium e Low seguem o *Accelerate* [Forsgren et al. 2018]; a janela vai de 2025-10-01 a 2026-09-30.

Tabela 1. Questões de pesquisa e hipóteses informais.

RQ	Pergunta	Hipótese
RQ01†	Qual é a frequência de deploy?	Bem abaixo de 1/semana (0,1–0,3); poucos Elite.
RQ02†	Qual é o lead time (a) por release e (b) por commit?	Semanas; (a) claramente maior que (b).
RQ03	Qual é a taxa de falha (a) do CI e (b) das entregas?	(a) de 10% a 25%, bem acima de (b), abaixo de 10%.
RQ04	Quanto dura a recuperação após falha de CI?	Entre 1 hora e 1 dia; menos de 10% censurados.
RQ05	Frequência de deploy se relaciona com a taxa de falha?	Sem *trade-off*: $\|\rho\| < 0{,}3$ nas duas variantes.
RQ06	Que características se associam a melhor desempenho?	Contribuidores é o fator principal; efeitos pequenos.
RQ07	A classificação DORA muda com a definição?	25% a 50% mudam; κ entre 0,4 e 0,6; um degrau.
RQ08†	Qual é a *rework rate* e como se compara ao CFR (b)?	Maior que o CFR (b) na maioria; correlacionada a ele, mas menos ligada à frequência.

† Hipóteses escritas depois de os resultados existirem (não contam como previsão); RQ03 a RQ06 antes dos dados; RQ07 antes do seu resultado.

3. Metodologia

3.1. Principais Desafios

(i) **Limites da API**: a busca e a listagem de runs devolvem no máximo 1.000 resultados, o que exigiu fatiar por faixas de estrelas e por mês, além de pausar no *rate limit*; comparações de commits muito longas retornavam HTTP 500 em páginas profundas. (ii) **Ambiguidade das métricas**: o lead time depende de qual commit representa a release, e a "release corretiva" do CFR (b) não existe na API, exigindo uma heurística validada contra rótulos humanos. (iii) **Volume**: cerca de 77 mil respostas da API, tratadas com cache em disco e retomada.

3.2. Tomadas de Decisão

Deploy é a release publicada (sem rascunho nem pré-release); pré-releases e tags entram só como variantes da RQ07. No **CI**, só o *default branch* e `event=push`: `success` é sucesso; `failure`, `timed_out` e `startup_failure` são falha; o resto é ignorado. **Inclusão**: pelo menos 5 releases e 50 runs válidos na janela, com os candidatos embaralhados por semente fixa. **Censura**: falhas sem recuperação e releases dos últimos 7 dias são contadas, nunca descartadas. **Estatística**: mediana e IQR; Spearman e Kruskal-Wallis com correção de Holm [Wohlin et al. 2012]. **WIP**: no máximo 1 a 2 Issues em andamento por integrante.

A Tabela 2 mostra o funil de seleção. Na **validação manual**, os três integrantes rotularam de forma independente 60 repositórios e 300 releases sorteados, com κ de Fleiss de 0,91 (tipo do projeto), 0,38 (entregas reais, efeito do desbalanceamento: 57 de 60 unânimes) e 0,86 (release corretiva). A heurística adotada (v3) alcançou F1 = 0,734 contra esse consenso.

Tabela 2. Funil de seleção dos repositórios.

Etapa	Restantes	Descartados (motivo)
Candidatos da busca (4 faixas de estrelas)	4.000	–
Processados até completar a amostra	1.328	2.672 (não processados)
Com GitHub Actions	939	389 (sem workflows)
≥ 5 releases na janela	373	566 (poucas releases)
≥ 50 runs válidos na janela = **amostra final**	**300**	73 (poucos runs)

Tabela 3. Entregas por sprint e responsáveis (Issues).

Sprint	Entregas	Responsáveis (Issues)
S01	Pipeline base (100 repos), testes e CI, hipóteses	Arlindo #1–5, 19, 20; Arthur #6–10, 17, 21; Camila #11–16, 18, 22
S02	300 repos, variantes, dicionário, validação manual, CFR (b)	Arlindo #23–25, 30, 39, 81; Arthur #26–28, 31, 37; Camila #29, 32–36, 38
S03	Análises RQ01–RQ08, resultados e discussão	Arlindo #40–42, 48, 98; Arthur #43, 44, 49; Camila #45–47, 50
Final	Replicação cruzada	pendente (#51–59)

3.3. Etapas

Configuração do processo. Board "Kanban" no GitHub Projects com as colunas Backlog $\rightarrow$ Ready $\rightarrow$ In progress $\rightarrow$ Done e WIP de 1 a 2 cards por integrante; a revisão ocorre no Pull Request, mergeado por um revisor humano com o CI verde.

3.4. Ferramentas

Python 3.12; API REST do GitHub [GitHub 2026] via script próprio com `requests` (sem bibliotecas de terceiros para a API); pandas, SciPy, statsmodels e scikit-learn para dados e estatística; Matplotlib para os gráficos; pytest, pytest-cov e GitHub Actions para a integração contínua; GitHub Projects (v2) para o processo.

3.5. Tabela de Métricas

Tabela 4. Métricas e definições operacionais (fonte: API REST do GitHub).

RQ	Métrica	Definição operacional	Unidade
RQ01	Frequência	Releases publicadas na janela $\div$ 52,1 semanas	rel./semana
RQ02	Lead time (a)	Data da release $-$ `commit.author.date` do commit mais antigo desde a anterior; mediana por repo	dias
RQ02	Lead time (b)	Mediana sobre todos os commits de todas as releases	dias
RQ03	CFR (a)	Falhas $\div$ (falhas $+$ sucessos) dos runs do default branch com `push`	fração
RQ03	CFR (b)	Releases seguidas em até 7 dias por release corretiva $\div$ releases avaliadas	fração
RQ04	Recuperação	Por workflow: sucesso $-$ início da primeira falha; mediana por repo	horas
RQ05/06	Associação	Spearman; Kruskal-Wallis com $\varepsilon^2 = H/(n-1)$ e Holm	–
RQ07	Sensibilidade	% que muda de categoria e κ ponderado linear	%, κ
RQ08	Rework rate	Releases corretivas $\div$ total de releases, sem censura	fração

3.6. Inovações Propostas pelo Grupo (30% da nota)

RQ08 – *rework rate*: proporção de releases corretivas, que não depende da janela de 7 dias do CFR (b) (Figura 8). **Heurística em três versões**: v1 literal ao enunciado (F1 =

0,574), v2 com tratamento de *backports* (0,698) e v3, que ignora commits de CI, documentação e dependências e separa patches com funcionalidades (0,734); ela sustenta CFR (b), RQ05, RQ07 e RQ08. **Amostragem sistemática**: no máximo 100 comparações por variante, espalhadas pela janela, o que viabilizou a combinação C3 da RQ07.

4. Resultados

4.1. Coleta de Dados

A amostra final tem 300 repositórios (Tabela 2). Destes, 23 não têm tempo de recuperação (20 sem episódio de falha e 3 só com episódios censurados) e ficam sem classificação DORA geral. Valores extremos foram mantidos, já que mediana e IQR são robustos a eles; lead times negativos (*rebase* e *squash*) foram descartados e contados.

4.2. Visualização Gráfica

Nas figuras, **azul = variante (a)** e **laranja = variante (b)**; as faixas cinza mostram o previsto pela hipótese e as linhas verticais finas, os cortes DORA.

RQ01 – Qual é a frequência de deploy?

H1 (escrita depois da coleta)
Mediana bem abaixo de 1 deploy por semana (0,1 a 0,3), cauda à direita e poucos Elite.

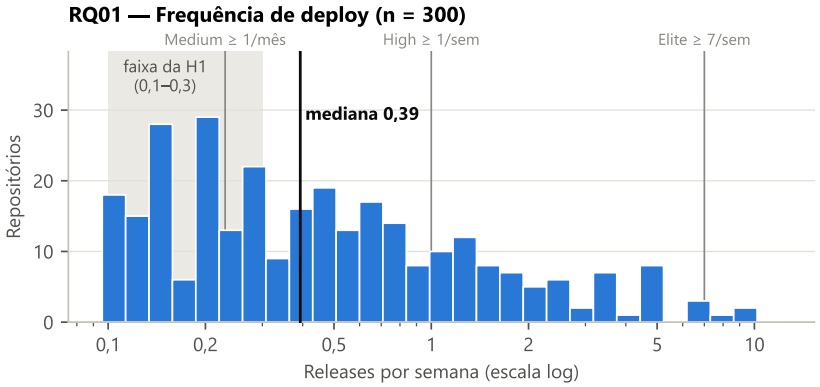


Figura 1. Frequência de deploy (releases por semana). *Gráfico escolhido: distribuição assimétrica, histograma em escala log.* [Grupo 1 – PUC Minas 2026]

Valores-chave: mediana de 0,39 (IQR 0,19–0,94); 5 repositórios (1,7%) Elite e 210 (70%) em Medium ou Low.

Resultado vs. Hipótese: Parcialmente confirmada. Mediana acima da faixa, mas abaixo de 1 por semana e com poucos Elite; como foi escrita depois da coleta, não conta como confirmação.

RQ02 – Qual é o lead time para mudanças?

H2 (escrita depois da coleta)

Lead time de semanas; (a) por release claramente maior que (b) por commit.

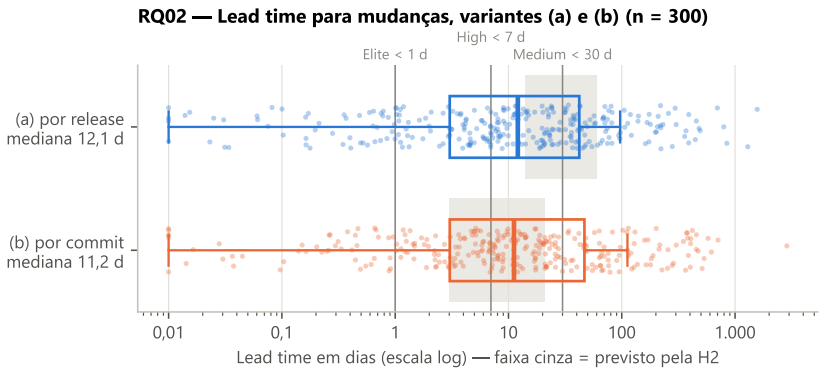


Figura 2. Lead time por repositório; valores abaixo de 0,01 dia aparecem em 0,01. *Gráfico escolhido: duas variantes nos mesmos repositórios, boxplot pareado com os pontos.* [Grupo 1 – PUC Minas 2026]

Valores-chave: (a) mediana de 12,1 dias (IQR 3,0–42,2); (b) 11,2 dias (IQR 3,0–46,8); Spearman entre as variantes $\rho = 0{,}76$.

Resultado vs. Hipótese: Refutada. As variantes ficaram quase iguais no centro, e a cauda de (b) é até mais longa.

RQ03 – Qual é a taxa de falha das mudanças?

H3

CFR (a), pelo CI, entre 10% e 25%, bem acima do CFR (b), pelas entregas, abaixo de 10%.

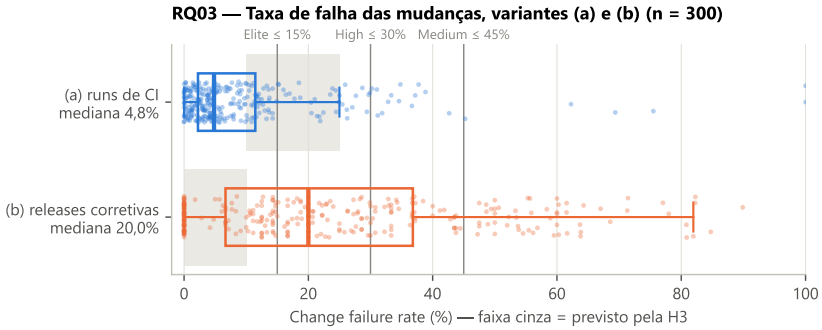


Figura 3. Change failure rate por repositório. *Gráfico escolhido: duas variantes nos mesmos repositórios, boxplot pareado com os pontos.* [Grupo 1 – PUC Minas 2026]

Valores-chave: CFR (a) com mediana de 4,8% (IQR 2,2%–11,5%); CFR (b) de 20,0% (IQR 6,7%–36,8%).

Resultado vs. Hipótese: Refutada. A ordem se inverteu: as muitas execuções de CI bem-sucedidas diluem as falhas em (a).

RQ04 – Quanto tempo leva a recuperação após uma falha de CI?

H4

Mediana entre 1 hora e 1 dia, distribuição assimétrica e menos de 10% de episódios censurados.

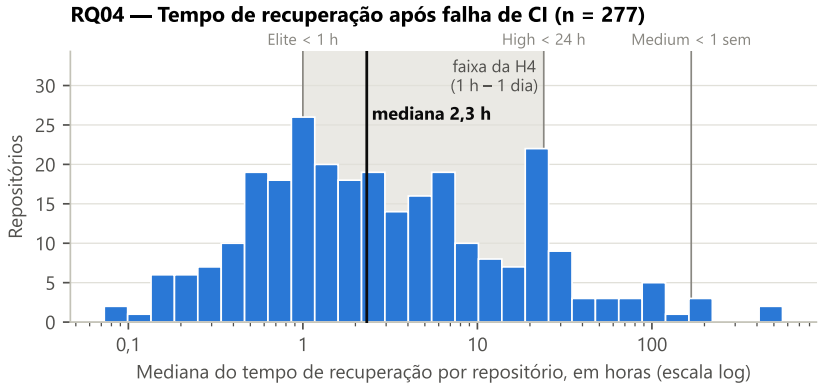


Figura 4. Mediana do tempo de recuperação por repositório. ***Gráfico escolhido: distribuição assimétrica, histograma em escala log.*** **[Grupo 1 – PUC Minas 2026]**

Valores-chave: mediana de 2,3 horas (IQR 0,9–9,3; $n = 277$); 122 de 20.707 episódios (0,6%) censurados.

Resultado vs. Hipótese: Confirmada. Mediana dentro da faixa, cauda longa e censura bem abaixo de 10%.

RQ05 – Maior frequência de deploy significa mais ou menos falhas?

H5

Sem *trade-off*: correlação fraca ($|\rho| < 0{,}3$) nas duas variantes; se houver sinal, levemente negativo para o CFR (b).

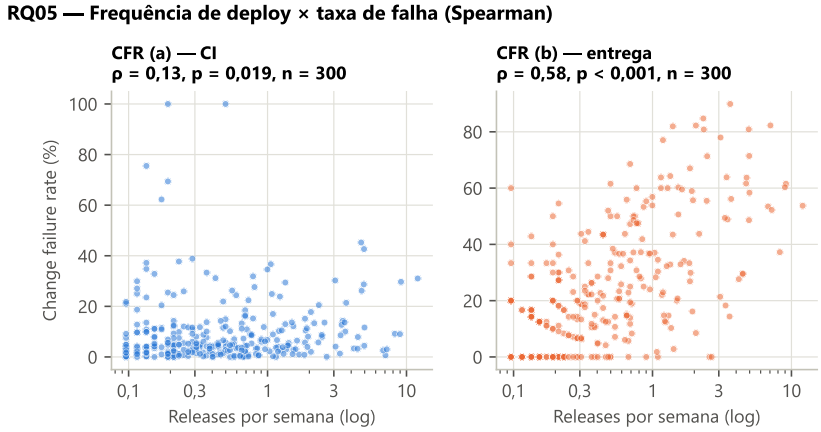


Figura 5. Frequência de deploy contra CFR (a) e CFR (b). ***Gráfico escolhido: relação entre duas métricas numéricas, dispersão com eixo x em log.*** **[Grupo 1 – PUC Minas 2026]**

Valores-chave: CFR (a): $\rho = 0{,}13$ ($p = 0{,}019$); CFR (b): $\rho = 0{,}58$ ($p < 0{,}001$); $n = 300$.

Resultado vs. Hipótese: Parcialmente confirmada. Fraca em (a); em (b), positiva e moderada, em boa parte pela janela de 7 dias da própria definição. Correlação não implica causalidade.

RQ06 – Que características se associam a melhor desempenho DORA?

H6

Contribuidores é o fator mais associado à velocidade; tipo de projeto também pesa; estrelas e idade pouco; efeitos pequenos.

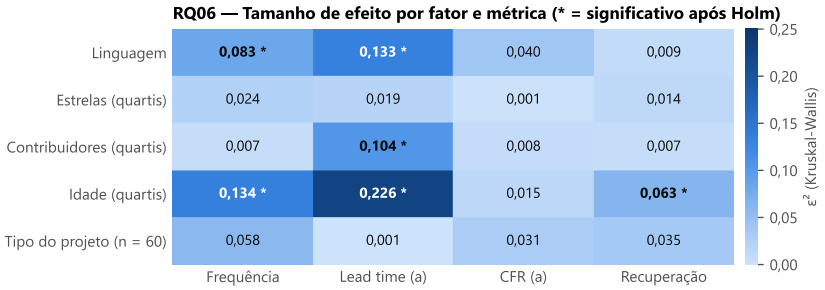


Figura 6. Tamanho de efeito ε^2 por fator e métrica; * = significativo após Holm. *Gráfico escolhido: grade fator × métrica, heatmap de uma só matiz.* [Grupo 1 – PUC Minas 2026]

Valores-chave: 6 de 20 testes significativos. Idade é o fator mais forte (lead time $\varepsilon^2 = 0{,}226$, frequência 0,134, recuperação 0,063), seguida da linguagem; contribuidores só no lead time (0,104); nada no CFR (a).

Resultado vs. Hipótese: Majoritariamente refutada. A idade, e não contribuidores, é o fator principal; contribuidores aparece só no lead time e com sinal oposto. Estrelas sem efeito, como previsto; tipo do projeto com pouco poder ($n = 60$).

RQ07 – A classificação DORA muda conforme a definição adotada?

H7 (escrita antes do resultado da RQ07)

De 25% a 50% dos repositórios mudam de categoria; κ moderado (0,4–0,6); mudanças de um degrau; menor concordância em C1×C2.

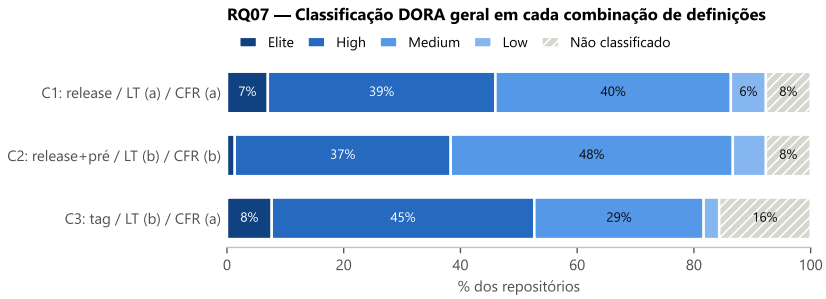


Figura 7. Classificação DORA geral por combinação (unidade de deploy / lead time / CFR); C1 é a referência. *Gráfico escolhido: proporção de categorias ordenadas, barras 100% empilhadas.* [Grupo 1 – PUC Minas 2026]

Valores-chave: mudaram de categoria 32,5% em C1×C2 ($\kappa = 0{,}50$), 24,1% em C1×C3 ($\kappa = 0{,}66$) e 33,6% em C2×C3 ($\kappa = 0{,}50$). Em C1, 7% Elite, 39% High, 40% Medium, 6% Low e 8% sem classificação.

Resultado vs. Hipótese: Parcialmente confirmada. Proporção e degraus como previsto; κ acima da faixa em C1×C3; o que mais pesou foi a variante do CFR, não o lead time.

RQ08 (bônus) – Qual é a *rework rate* e como se compara ao CFR (b)?

H8 (escrita antes do resultado da RQ07)

A rework rate será maior que o CFR (b) na maioria dos repositórios, porque conta toda release corretiva, e não só as corrigidas em até 7 dias. As duas serão correlacionadas, por usarem a mesma heurística, mas a rework rate dependerá menos da frequência de deploy.

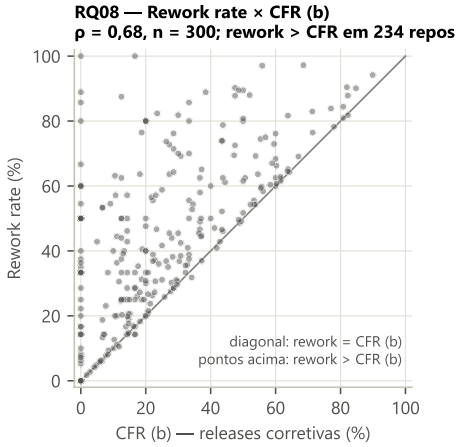


Figura 8. Rework rate contra CFR (b); acima da diagonal, rework maior. *Gráfico escolhido: duas métricas na mesma escala, dispersão com a diagonal* $y = x$ [Grupo 1 – PUC Minas 2026]

Valores-chave: mediana de 40% (IQR 20%–62%) contra 20% do CFR (b); $\rho = 0{,}68$; rework maior em 234 de 300 repositórios.

Resultado vs. Hipótese: De acordo com os dados. A rework rate é maior em 234 de 300 repositórios (78%), as duas medidas são correlacionadas ($\rho = 0{,}68$) e a ligação com a frequência é bem menor ($\rho = 0{,}19$, contra 0,58 do CFR (b)). Como a hipótese foi escrita depois dos resultados, não conta como confirmação.

4.3. Discussão

Das hipóteses escritas antes dos dados (H3 a H7), só a de recuperação (H4) se confirmou por inteiro. As surpresas foram a inversão dos CFRs, porque o CI falha pouco diante das muitas execuções bem-sucedidas, e o peso da idade: projetos novos são mais rápidos, e contribuidores, que esperávamos ser o fator principal, só aparece no lead time e com sinal contrário, provavelmente porque andam junto com a idade. Sobre velocidade $\times$ estabilidade [Forsgren et al. 2018], não há *trade-off* forte pelo CI; a correlação com o CFR (b) parece vir da janela de 7 dias, já que a *rework rate* (inovação do grupo), que não a usa, se correlaciona só fracamente com a frequência. As conclusões são robustas só em parte: um quarto a um terço dos repositórios muda de categoria com a definição, sempre por um degrau, então os resultados valem para a definição adotada (C1). Ver também o vídeo indicado no modelo da disciplina [YouTube sd].

4.3.1. Ameaças à validade

Seguindo Wohlin et al. [Wohlin et al. 2012]: **construto** – release não é deploy em produção e falha de CI não é falha para o usuário; a heurística corretiva (F1 = 0,734) foi ajustada e avaliada na mesma amostra-ouro. **Interna** – a idade se confunde com outros fatores; `commit.author.date` é distorcida por *rebase*; na rotulagem, um avaliador usou um modelo de linguagem e outro revisou sugestões por palavras-chave. **Externa** – a amostra cobre projetos populares que usam releases do GitHub (só 40% dos que têm Actions publicaram 5 releases). **Conclusão** – 20 testes na RQ06 (Holm); tipo do projeto com $n = 60$; 23 repositórios sem recuperação.

4.3.2. Replicação cruzada

O repositório foi preparado com uma subamostra fixa de 30 repositórios e um passo a passo no README.

5. Conclusão

Os repositórios open-source populares publicam poucas releases por semana, levam semanas entre commit e publicação e se recuperam rápido de falhas de CI; o CI raramente falha, mas uma parte relevante das releases é seguida por correção. Não há *trade-off* claro entre velocidade e estabilidade, a idade pesa mais que popularidade ou tamanho da comunidade, e a classificação DORA depende da definição, sobretudo da variante do CFR. As principais limitações são os proxies de deploy e de falha, a heurística validada na mesma amostra em que foi ajustada e a amostra restrita a projetos populares. Como trabalho futuro: validar a heurística numa amostra independente, repetir a RQ06 em C2 e C3 e analisar a tendência da *rework rate* na janela.

Referências

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

GitHub (2026). GitHub REST API documentation. `https://docs.github.com/rest`. Acesso em: 22 out. 2026.

Grupo 1 – PUC Minas (2026). Análise de dados aplicada à experimentação em engenharia de software: Trabalho final. Material da disciplina Laboratório de Experimentação de Software, Prof. Danilo Maia. Guia de escolha de gráficos (seções 7 a 9).

Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.

YouTube (s.d.). Vídeo indicado no modelo de relatório da disciplina. `https://www.youtube.com/shorts/YwnaeO95AN8`. Acesso em: 22 out. 2026.

Zuse, H. (2013). *A Framework of Software Measurement*. Walter de Gruyter.